Inteligencia Artificial en Eventide

Este documento explica los fundamentos teoricos de IA utilizados en Eventide: por que cada tecnica, que alternativas se consideraron, y que evidencia experimental justifica la eleccion.

Audiencia: lectores con interes academico en IA, NLP y representacion del conocimiento.

---

1. Representacion semantica con embeddings

Que es un embedding

Un embedding es una funcion que mapea un texto a un vector denso en un espacio de alta dimension. La propiedad clave es que textos con significado similar quedan cerca en ese espacio.

Formalmente, un modelo de embeddings aprende una funcion f: Texto -> R^n de manera que la similitud entre f(a) y f(b) aproxima la similitud semantica entre a y b. La similitud se mide normalmente con similitud coseno.

Modelos evaluados

Comparamos 3 modelos representativos de Sentence-BERT:

- paraphrase-multilingual-mpnet-base-v2 (768 dimensiones, 50+ idiomas).
- distiluse-base-multilingual-cased-v1 (512 dimensiones, 50+ idiomas).
- all-MiniLM-L6-v2 (384 dimensiones, solo ingles).

Alternativas rechazadas:

- Modelos monolingues como all-mpnet-base-v2: descartados por falta de soporte para eventos en idiomas no ingleses.
- Modelos gigantes como e5-mistral-7b: descartados por coste computacional.
- TF-IDF y BM25: baseline clasico, pero no captura semantica.

Justificacion de la eleccion

Resultados experimentales sobre 300 eventos y 20 queries:

- paraphrase-multilingual-mpnet-base-v2: NDCG@10 = 0.8118, Precision@10 = 0.7300, Recall@10 = 0.6667, latencia 43 ms.
- distiluse-base-multilingual-cased-v1: NDCG@10 = 0.7849, Precision@10 = 0.7450, Recall@10 = 0.4500, latencia 22 ms.
- all-MiniLM-L6-v2: NDCG@10 = 0.5888, Precision@10 = 0.4800, Recall@10 = 0.4500, latencia 11 ms.

Conclusion: el modelo elegido obtiene el mayor NDCG@10 y Recall@10. Aunque all-MiniLM-L6-v2 es 4 veces mas rapido, su calidad es 28 por ciento peor. distiluse es un buen compromiso pero su Recall es 22 por ciento inferior.

---

2. Busqueda vectorial con FAISS

El problema

Dado un conjunto de N embeddings y una query, el problema es encontrar los K mas similares. Para N grande, el escaneo lineal es demasiado lento.

Alternativas evaluadas

- Indice Flat (exacto): complejidad O(N), memoria minima. Ideal para N menor que 100k.
- HNSW (grafo): complejidad O(log N), 5 veces mas memoria. Ideal para N mayor que 500k.
- IVFFlat (clustering): complejidad O(sqrt(N)), requiere entrenamiento previo.

Justificacion

Con N entre 300 y 2000 eventos, el indice Flat es suficiente (aproximadamente 50 ms por query). Ademas:

- No tiene parametros que ajustar.
- Es 100 por ciento exacto.
- Combinado con sharding por ciudad, reduce el espacio efectivo.

Migracion futura: si el corpus crece a mas de 500k eventos, migraremos a HNSW.

---

3. Grafos de conocimiento

Que es un grafo de conocimiento

Un grafo de conocimiento es una estructura de nodos y aristas donde los nodos representan entidades y las aristas representan relaciones tipadas.

Eventide construye un grafo con NetworkX donde cada evento se conecta a:

- Su ciudad.
- Su categoria.
- Sus artistas.
- Otros eventos similares (con similitud coseno mayor a 0.88).

PageRank para re-ranking

El algoritmo PageRank mide la importancia de un nodo en funcion de sus conexiones entrantes. Los eventos con mayor PageRank son mas centrales en el grafo.

Uso en Eventide: los eventos con alto PageRank se usan como bonus en el ranking final.

Alternativas rechazadas

- Solo embeddings: no captura relaciones explicitas.
- RDF y OWL: mas expresivos pero excesivamente complejos para este dominio.
- GraphRAG de Microsoft 2024: interesante pero requiere LLMs locales viables.

Justificacion

El grafo aporta:

1. Razonamiento explicito, como "artistas que actuan en ciudades donde tambien toca X".
2. Re-ranking informado, subiendo eventos conectados con artistas o categorias populares.
3. Base para futuras extensiones (GraphRAG-ready).

---

4. Modelos de lenguaje para narracion

Que es un LLM

Un Large Language Model es un modelo autoregresivo entrenado para predecir el siguiente token. Dado un prompt, genera una secuencia de texto coherente.

Uso en Eventide: generar una explicacion en lenguaje natural de la agenda recomendada.

Modelos considerados

- Gemini 1.5 Flash: rapido, gratuito en su tier, buena calidad. Requiere API key.
- GPT-4: excelente calidad pero costoso por token.
- LLaMA 3 local: sin coste API, privacidad. Requiere GPU, mas lento.
- Fallback local: sin dependencias, calidad muy inferior.

Justificacion

Gemini Flash ofrece latencia aceptable (aproximadamente 2 segundos por narracion), buena calidad en espanol, y free tier generoso.

Fallback: si el LLM falla o tarda mas de 8 segundos, se usa una narracion plantilla (menos natural pero funcional).

Filtros de sensatez

Antes de pasar datos al LLM, se filtran:

- Distancias mayores a 30 km: no se mencionan.
- Huecos mayores a 24 horas: no se mencionan.
- Datos absurdos: descartados.

Objetivo: reducir alucinaciones y evitar narrativas raras.

---

5. Arquitectura neuro-simbolica

Eventide combina dos paradigmas de IA:

- Subsimbolico: embeddings (redes neuronales).
- Simbolico: grafo de conocimiento (logica explicita).

Ventaja: los embeddings capturan semantica difusa; el grafo captura relaciones explicitas. Juntos son mas potentes que cada uno por separado.

---

6. Referencias

- Reimers y Gurevych (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. EMNLP.
- Johnson, Douze y Jegou (2019). Billion-scale similarity search with GPUs. IEEE Transactions on Big Data.
- Page, Brin, Motwani y Winograd (1999). The PageRank Citation Ranking. Stanford InfoLab.
- Lewis et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS.