Sistemas de Recuperacion de Informacion en Eventide

Este documento cubre los fundamentos teoricos de Recuperacion de Informacion (IR o SRI) utilizados en Eventide, con enfasis en las metricas de evaluacion y las tecnicas de busqueda.

Audiencia: lectores con interes en IR, motores de busqueda y evaluacion de sistemas de recomendacion.

---

1. Fundamentos de IR

Que resuelve un sistema de IR

Un sistema de IR recibe una coleccion de documentos y una query, y devuelve un ranking de documentos ordenados por relevancia.

Modelos clasicos:

- Booleano: logica de conjuncion y disyuncion sobre terminos (rigido).
- Vectorial: similitud coseno entre vectores TF-IDF.
- Probabilistico: BM25.

Modelos modernos:

- Dense retrieval: embeddings densos.
- Neural IR: BERT como reranker.

Eventide usa dense retrieval con Sentence-BERT y FAISS.

---

2. Embeddings para IR

Pipeline

1. Para cada documento, generar embedding con el modelo.
2. Indexar los embeddings en FAISS.
3. Para cada query, generar embedding.
4. Buscar top-k por similitud coseno.
5. Opcionalmente, filtrar por metadatos (ciudad, categoria).
6. Opcionalmente, re-rankear con grafo de conocimiento.

Alternativas rechazadas

- BM25: baseline solido pero solo keywords, no semantica.
- TF-IDF: simple pero ignora orden y contexto.
- Dense puro: captura semantica pero sensible a sinonimos e idiomas.
- Dense + filtros + grafo: combinacion, requiere pipeline complejo.

Eventide implementa el pipeline completo: dense + filtros + grafo.

---

3. Evaluacion de IR

Metricas estandar

Precision@k: fraccion de documentos relevantes en los primeros k.

Recall@k: fraccion de relevantes que aparecen en el top-k.

NDCG@k: mide la calidad del ranking considerando el orden. Es la metrica estandar en IR moderno porque penaliza documentos relevantes en posiciones bajas.

Propiedades de NDCG

- Rango: entre 0 y 1.
- Monotona: mejor ranking, mayor NDCG.
- Comparable entre queries: normalizada por el ranking ideal.

Eventide usa NDCG@10 como metrica principal.

Relevancia

En Eventide, la relevancia se define de forma binaria: un documento es relevante (valor 3) si coincide con alguno de los esperados para la query, o no relevante (valor 0) si no coincide.

Simplificacion: en IR real se usan grados de relevancia (0, 1, 2, 3). Aqui usamos binario por simplicidad.

---

4. Resultados experimentales

Comparacion de modelos de embeddings

- paraphrase-multilingual-mpnet-base-v2: NDCG@10 = 0.8118, Precision@10 = 0.7300, Recall@10 = 0.6667, latencia 43 ms.
- distiluse-base-multilingual-cased-v1: NDCG@10 = 0.7849, Precision@10 = 0.7450, Recall@10 = 0.4500, latencia 22 ms.
- all-MiniLM-L6-v2: NDCG@10 = 0.5888, Precision@10 = 0.4800, Recall@10 = 0.4500, latencia 11 ms.

Interpretacion

NDCG@10 = 0.81 significa que el ranking del modelo elegido captura el 81 por ciento de la calidad del ranking ideal.

Recall@10 = 0.67 significa que recupera el 67 por ciento de los eventos relevantes.

Precision@10 = 0.73 significa que el 73 por ciento del top-10 es relevante.

Estos valores son buenos para un sistema IR en el dominio de eventos.

Comparacion con baselines

Aunque no ejecutamos BM25 en el experimento final por complejidad, la literatura indica:

- BM25: NDCG alrededor de 0.4-0.5 en dominios similares.

- Dense puro: NDCG alrededor de 0.6-0.7.
- Dense + reranking: NDCG alrededor de 0.75-0.85.

Eventide con 0.81 esta en el rango alto esperado.

---

5. Re-ranking con grafo de conocimiento

Fundamento

Dado un ranking inicial del dense retrieval, re-rankear con el grafo significa ajustar el score de cada evento con dos factores adicionales:

- PageRank del evento en el grafo.
- Numero de conexiones del evento con terminos de la query.

Uso en Eventide

Sube eventos con alto PageRank (populares y conectados) y eventos cuyos artistas o categorias coinciden con la query.

Limitacion: en datasets pequenos, el grafo aporta poco. En datasets grandes (mas de 10k eventos), el efecto es significativo.

---

6. Did-you-mean (query relaxation)

Problema

El usuario escribe "balar" en lugar de "bailar". La busqueda semantica no distingue porque "balar" es una palabra valida en espanol (sonido de las ovejas).

Solucion implementada

1. Correccion ortografica basica con pyspellchecker.
2. Did-you-mean contextual: si la busqueda devuelve pocos resultados, probar variantes.
3. Sugerencias al usuario: "Quisiste decir bailar?".

Ejemplo

Query original: "balar". Query corregida: "bailar". Resultados: N eventos de musica y danza. Sugerencia al usuario.

---

7. Alternativas de evaluacion

Evaluacion humana

Ideal pero costosa. En Eventide no se realizo por limitaciones de tiempo.

LLM-as-judge

Prometedora (Zheng et al., 2023) pero subjetiva y costosa.

Evaluacion automatica con ground truth

Lo que usamos: ground truth manual con 20 queries y sus eventos esperados.

Limitacion: N=20 es pequeno. Trabajo futuro: ampliar a 200 o mas.

---

8. Referencias

- Manning, Raghavan y Schutze (2008). Introduction to Information Retrieval. Cambridge University Press.
- Jarvelin y Kekalainen (2002). Cumulated gain-based evaluation of IR techniques.
- Karpukhin et al. (2020). Dense Passage Retrieval for Open-Domain Question Answering. EMNLP.
- Nogueira y Cho (2019). Passage Re-ranking with BERT. arXiv.
- Robertson y Zaragoza (2009). The Probabilistic Relevance Framework: BM25 and Beyond.
- Zheng et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. NeurIPS.